

Análisis Bayesiano

Naren Mantilla & Alexander Sepúlveda

Universidad Industrial de Santander

3 de diciembre de 2019

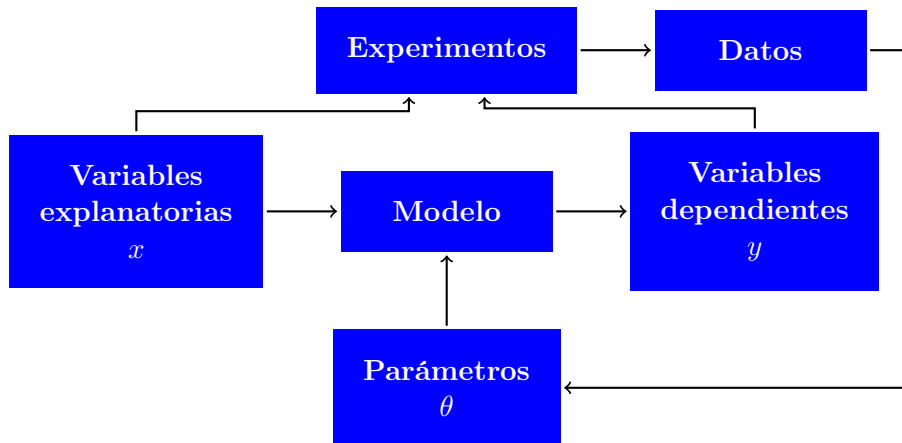
Curso: *Marco Bayesiano para el análisis de datos, calibración de parámetros y modelamiento inverso* **David A. Barajas-Solano**

- Egresado de la UIS – Ingeniería Civil
- Ph.D. en ciencias de la ingeniería, UC San Diego
- Científico en Pacific Northwest National Laboratory
- Perfil científico en <https://www.dbarajassolano.com>

- 1 Conceptos Básicos
- 2 Teoría de Probabilidad
- 3 Variables Aleatorias
- 4 Probabilidad Conjunta y Marginal
- 5 Modelamiento probabilístico

1 Conceptos Básicos

- *Modelos* son objetos matemáticos usados para describir fenómenos en ciencia e ingeniería.
- Los modelos son *calibrados* utilizando datos experimentales.



- *Ley de Ohm:*

$$V = R \times I$$

- Parámetros: Resistencia R .

- *Ley de Ohm:*

$$V = R \times I$$

- Parámetros: Resistencia R .
- *Modelo logístico para variables categóricas:*

$$\log \frac{P(y = 1)}{P(y = 0)} = \alpha + \beta x$$

- Variable categórica dependiente $y = \{0, 1\}$.
- Variable explicativa continua x .
- Parámetros $\theta = \alpha, \beta$.

2 Teoría de Probabilidad

- Como toda teoría matemática, la teoría de probabilidades no representa realidades físicas. En cambio, es útil para representar conceptos.
- Nuestro objetivo es *modelar* información de manera consistente y fácil de interpretar.
- El modelador, ud., juega un rol fundamental.
- El modelador toma decisiones subjetivas.
- La validez de éstas suposiciones está en la utilidad de los resultados.

Experimento

Resultados
 Ω

Variables aleatorias
 $X: \Omega \rightarrow C$

Eventos
 \mathcal{F}

Probabilidades
 $P: \mathcal{F} \rightarrow [0, 1]$

Resultado: *Posible resultado de un experimento aleatorio*

Espacio de resultados Ω : “Conjunto” de resultados

Ejemplos

- Lanzar una moneda

$$\Omega = \{\text{cara}, \text{sello}\}$$

- Lanzar un dado

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

- Lanzar dos monedas

$$\Omega = \{(\text{cara}, \text{cara}), (\text{cara}, \text{sello}), (\text{sello}, \text{cara}), (\text{sello}, \text{sello})\}$$

El espacio de resultados puede ser...

- **Finito contable**

Ejemplo: Elegir un número de 1 a 10

$$\Omega = \{1, 2, 3, \dots, 10\}$$

- **Infinito contable**

Ejemplo: Elegir un número de 0 a infinito

$$\Omega = \mathbb{N}^0 = \{0, 1, 2, \dots\}$$

- **Incontable**

Ejemplo: Elegir un número real no negativo


$$\Omega = \mathbb{R}^+ = [0, \infty)$$

Definición: Funciones

La notación

$$f: A \rightarrow B$$

define la función $f(\cdot)$ que asigna un elemento de B a un elemento A . E.g., $f(a) = b$ indica que la función asocia $b \in B$ a $a \in A$



Funciones de los resultados que representan cantidades asociadas al resultado del experimento

$$X: \Omega \rightarrow C$$

Ejemplos

- Lanzar dos dados

$$\Omega = \{(1, 1), (1, 2), (1, 3), \dots, (2, 1), (2, 2), \dots (6, 6)\}$$

$$\omega \in \Omega, \quad \omega = (\omega_1, \omega_2)$$

Variable aleatoria: Suma de los dos dados

$$X: \Omega \rightarrow \mathbb{N}, \quad X(\omega) = \omega_1 + \omega_2$$

Ejemplos

- Suma de dos dados: $X: \Omega \rightarrow \mathbb{N}$, $X(\omega) = \omega_1 + \omega_2$

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Pueden ser *discretas* o *continuas* **Ejemplo:** Altura, ingreso y género de una población

$$\Omega = \{\text{personas en la población}\}$$

- **Discreta:** Género

$$G: \Omega \rightarrow \{\text{masc., fem., } \dots\}$$

- **Continúa:** Altura

$$A: \Omega \rightarrow \mathbb{R}$$

- **Ingreso:** Variable continua o discreta?

Evento: *Subconjunto de resultados del experimento*

Campo de eventos \mathcal{F} : “Conjunto” de eventos

Definición: Conjunto-poder

Para Ω *contable*, una selección común de campo de eventos es el conjunto-poder 2^Ω , que contiene los siguientes eventos:

- Cada resultado (evento elemental)
- Todos los subconjuntos de Ω
- Todos los resultados (osea Ω)
- Ningún resultado (conjunto vacío, \emptyset)

Ejemplo: Lanzar un dado

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

Algunos eventos en el conjunto potencia (*power set*) $\mathcal{F} = 2^\Omega$:

- El número 3
- Un número par
- Un número menor a 4
- Un número entre 2 y 5
- Cualquier número (Ω)
- Ningún número (\emptyset)

Ejemplo: Lanzar dos dados

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Ambos dados menor o igual a 4.

Ejemplo: Lanzar dos dados

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Dado # 1...

- E_1 : Menor a 3.
- E_2 : Mayor a 5.

Eventos E_1 y E_2 son *Mutuamente excluyentes*.

También es posible definir eventos en términos de los valores de variables aleatorias.

Ejemplo: Lanzar dos dados, suma $X(\omega) = \omega_1 + \omega_2$

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Suma X mayor o igual a 7.

También es posible definir eventos en términos de los valores de variables aleatorias.

Ejemplo: Lanzar dos dados

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

Suma mayor o igual a 7, pero el dado # 2 es 3 o mayor.

Definición: Axiomas de probabilidades

Las probabilidades son...

- 1 ... cantidades reales no negativas asociadas a cada evento en \mathcal{F} ...

$$P: \mathcal{F} \rightarrow \mathbb{R}^+$$

- 2 ... aditivas sobre eventos mutuamente excluyentes:

$$\text{Si } A \cap B = \emptyset, \text{ entonces } P(A \cup B) = P(A) + P(B)$$

- 3 ... que suman a 1 sobre el conjunto de resultados

$$P(\Omega) = 1$$

Definición: Axiomas de probabilidades

Las probabilidades son...

- 1 ... cantidades reales no negativas asociadas a cada evento en \mathcal{F} ...

$$P: \mathcal{F} \rightarrow \mathbb{R}^+$$

- 2 ... aditivas sobre eventos mutuamente excluyentes:

$$\text{Si } A \cap B = \emptyset, \text{ entonces } P(A \cup B) = P(A) + P(B)$$

- 3 ... que suman a 1 sobre el conjunto de resultados

$$P(\Omega) = 1$$

Los axiomas implican que $0 \leq P(E) \leq 1$ para $E \in \mathcal{F}$

Ejemplo: Lanzar dos dados, suma $X(\omega) = \omega_1 + \omega_2$

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

- $E_i, i \in [1, 36]$: Eventos elementales
- $P(E_i) = 1/36 \approx 28 \%$
- $P(X \geq 7) = 21/36 \approx 58 \%$

- Hasta ahora probabilidades se han definido de manera enteramente *abstracta*.
- Probabilidad es una *medida*: “Área” o “masa” asociada a una región (evento) del espacio de resultados.
- ¿Qué significa que un evento tenga probabilidad de 58 %?

- Interpretación *frecuentista*: Si el experimento se ejecuta n veces, se observará un 58 % de las veces el evento en cuestión.

- Interpretación *frecuentista*: Si el experimento se ejecuta n veces, se observará un 58 % de las veces el evento en cuestión.
- Cuál es la interpretación adecuada para la probabilidad de eventos que sólo ocurren una vez?
- E.g. el evento “llover mañana”: ¡Sólo hay –un– mañana!

- Interpretación *frecuentista*: Si el experimento se ejecuta n veces, se observará un 58 % de las veces el evento en cuestión.
- Cuál es la interpretación adecuada para la probabilidad de eventos que sólo ocurren una vez?
- E.g. el evento “llover mañana”: ¡Sólo hay –un– mañana!
- **Probabilidades como medida de (in)certidumbre.**

Considérese la variable aleatoria continua

$$A: \Omega \rightarrow C$$

Considérese la variable aleatoria continua

$$A: \Omega \rightarrow C$$

¿Qué eventos podemos definir en términos de los valores de A ?

Para $C \equiv \mathbb{R}$ y cierto valor $a \in C$...

- $P(A \leq a)$, $P(A > a)$, $P(a \leq A \leq b)$, etc.
- ¿ $P(A = a)$?

En general, $A = a$ es un evento con probabilidad trivial ($= 0$).

- Elementos de la teoría de probabilidades:
 - *Resultados, variables aleatorias, eventos, y probabilidades.*
- El modelamiento probabilístico en la práctica se basa en variables aleatorias, eventos asociados a variables aleatorias, y sus probabilidades.
- Usualmente, la definición de espacio de resultados Ω se puede tratar de manera implícita, i.e., no es necesario definir Ω explícitamente.

3 Variables Aleatorias

Ejemplo: Altura de una población

$$\Omega = \{\text{personas en la población}\}$$

- **Variable aleatoria:** Altura

$$A: \Omega \rightarrow \mathbb{R}$$

- **Eventos:**

- Altura mayor o igual a cierto valor a : $P(A \geq a)$
- Altura menor a cierto valor b : $P(A < b)$

Ejemplo: Altura de una población

$$\Omega = \{\text{personas en la población}\}$$

- **Variable aleatoria:** Altura

$$A: \Omega \rightarrow \mathbb{R}$$

- **Eventos:**

- Altura mayor o igual a cierto valor a : $P(A \geq a)$
- Altura menor a cierto valor b : $P(A < b)$

Si el interés es en las *propiedades* de la “altura”...

- ...no es necesario pensar en Ω
- Sólo hace falta pensar en A y los valores que puede tomar

Asocian probabilidades a los valores de variables aleatorias

- **Variables discretas:**

Función de *masa* de probabilidad (pmf)

- **Variables continuas:**

Función de *densidad* acumulada (cdf)

Función de *densidad* de probabilidad (pdf)

Función de masa de probabilidad (pmf)

- Variable aleatoria

$$X: \Omega \rightarrow C$$

- pmf $p_X: C \rightarrow [0, 1]$ definida como

$$p_X(c) = P(X = c) = P(\{\omega \in \Omega: X(\omega) = c\})$$

Función de masa de probabilidad (pmf)

Ejemplo: Lanzar dos dados. Suma $X: \Omega \rightarrow \mathbb{N}$

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

pmf:


- $p_X(1) = 0$
- $p_X(2) = 1/36$
- $p_X(3) = 2/36$
- $p_X(4) = 3/36$
- ...

Función de masa de probabilidad (pmf)

Ejemplo: Lanzar dos dados. Suma $X: \Omega \rightarrow \mathbb{N}$

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

pmf:



Función de masa de probabilidad (pmf)

- Para la variable aleatoria discreta $X: \Omega \rightarrow C$, se puede utilizar la pmf para calcular la probabilidad del evento del valor de X estar en cualquier subconjunto $B \subseteq C$:

$$P(X \in B) = \sum_{b \in B} p_X(b)$$

Función de masa de probabilidad (pmf)

- Para la variable aleatoria discreta $X: \Omega \rightarrow C$, se puede utilizar la pmf para calcular la probabilidad del evento del valor de X estar en cualquier subconjunto $B \subseteq C$:

$$P(X \in B) = \sum_{b \in B} p_X(b)$$

- Como consecuencia,

$$\sum_{b \in C} p_X(b) = 1$$

- **Ejemplo:** Lanzar dos dados

$$p_X(1) + p_X(2) + \cdots + p_X(11) + p_X(12) = 1$$


Función de densidad acumulada (cdf)

- Variable aleatoria

$$X: \Omega \rightarrow \mathcal{C}$$

- cdf $F_X(c) := P(X \leq c) \in [0, 1]$

- Ejemplo: Lanzar dos dados



Para la variable aleatoria $X: \Omega \rightarrow C$,

$$Q(p) := \inf\{x \in C: p \leq F_X(x)\}$$

- $Q(p)$ determina el menor valor x de X para el cual $P(X \leq x) \geq p$
- **Ejemplo:** Lanzar dos dados

p	0.1	0.2	0.5	0.7	0.9
$Q(p)$	4	5	7	8	10

- **Media/Esperanza/Valor esperado:**

$$\mu \equiv \mathbb{E}[X] := \sum_{x \in C} xp_X(x)$$

El promedio de n muestras de la variable aleatoria en el límite $n \rightarrow \infty$, i.e.,

$$\frac{x_1 + x_2 + \cdots + x_n}{n} \rightarrow \mathbb{E}[X]$$

- **Varianza:**

$$\sigma^2 \equiv \mathbb{E} \left[(X - \mu)^2 \right] = \sum_{x \in C} (x - \mu)^2 p_X(x)$$

Medida de desviación de la distribución alrededor de la media

- **Desviación estándar:** $\sigma = \sqrt{\sigma^2}$

- **Mediana:** $Q(05)$

- **Moda:** Valor mas probable, i.e, $\arg \max p_X(x)$

Ejemplo: Variables Aleatorias Discretas

Revisemos el *Notebook* de llamado “*rvs.ipynb*”.

- Ingrese a *Google Colaboratory*.
- Cargue el archivo `rvs.ipynb`.
- Siga paso a paso la parte de la guía correspondiente a *Variables aleatorias discretas*.

- **Variable aleatoria**

$$X: \Omega \rightarrow \mathcal{C}$$


- **cdf** $F_X(c) = P(X \leq c) \in [0, 1]$

Variables aleatorias continuas


- **Variable aleatoria**

$$X: \Omega \rightarrow \mathcal{C}$$

- **cdf** $F_X(c) = P(X \leq c) \in [0, 1]$
- **Ejemplo:** Variable aleatoria normal estándar



Función de densidad acumulativa




La cdf puede utilizarse para evaluar la probabilidad de varios escenarios:

- $P(X > 2) = 1 - P(X \leq 2) = 1 - F_X(2)$
- $P(04 \leq X \leq 2) = P(X \leq 2) - P(X \leq 04) = F_X(2) - F_X(04)$

Función de densidad de probabilidad (pdf)

- Para generalizar la pmf a variables aleatorias continuas, hay que introducir el concepto de *densidad*
- La pdf (o *densidad* o *distribución*) $p_X(a)$ cuantifica la cantidad de probabilidad en un intervalo alrededor de a relativa a la longitud del intervalo


Ejemplo: Variable aleatoria normal estándar



Función de densidad de probabilidad (pdf)

- Para generalizar la pmf a variables aleatorias continuas, hay que introducir el concepto de *densidad*
- La pdf (o *densidad* o *distribución*) $p_X(a)$ cuantifica la cantidad de probabilidad en un intervalo alrededor de a relativa a la longitud del intervalo

Ejemplo: Variable aleatoria normal estándar



Función de densidad de probabilidad (pdf)

- Si entendemos la probabilidad como la “masa” de una región del espacio de resultados (evento), la distribución $p_X(\cdot)$ indica la densidad en cada punto de esa región
- Para variables aleatorias *discretas*,

$$P(X \in B) = \sum_{b \in B} p_X(b)$$

- Para variables aleatorias *continuas*,

$$P(X \in B) = \int_B p_X(x) dx$$

- La integral $\int(\cdot)dx$ generaliza la suma \sum a variables aleatorias continuas.

- Para la variable aleatoria $X: \Omega \rightarrow C$, la pdf y la cdf están conectadas a través de la relación

$$F_X(a) = P(X \leq a) = \int_{-\infty}^a p_X(x) dx$$

- Como consecuencia de la definición,

$$P(X \in C) = \int_C p_X(x) dx = 1$$


Ejemplo: Variables Aleatorias Continuas

Revisemos el *Notebook* de llamado “*rvs.ipynb*”.

- Ingrese a *Google Colaboratory*.
- Cargue el archivo `rvs.ipynb`.
- Siga paso a paso la parte de la guía correspondiente a *Variables aleatorias continuas*.

Área bajo la curva


- La integral $\int_B p_X(x) dx$ puede interpretarse como el área bajo la curva $y = p(x)$ en el intervalo B .
- E.g., para el intervalo $B = (a, b)$,



- Dado que $\int_C p_X(x) dx = 1$, eso indica que el área bajo la pdf es 1.
- La cdf $F_X(a)$ corresponde al área bajo la curva entre $-\infty$ y a .


Ejemplo

- Variable aleatoria normal estándar $X \sim \mathcal{N}(0, 1)$.
- **Intervalo de mayor densidad (HDI)**: Para un valor $\alpha \in [0, 1]$, hay un intervalo $B = (a, b)$ para el cual:
 - $p_X(a) = p_X(b)$.
 - $P(X \in B) = 1 - \alpha$.
- Para $\alpha = 0.2$:



Ejemplo

- Variable aleatoria normal estándar $X \sim \mathcal{N}(0, 1)$.
- **Intervalo de mayor densidad (HDI)**: Para un valor $\alpha \in [0, 1]$, hay un intervalo $B = (a, b)$ para el cual:
 - $p_X(a) = p_X(b)$.
 - $P(X \in B) = 1 - \alpha$.
- Para $\alpha = 0.2$:



- Para la variable aleatoria $X \sim \mathcal{N}(\mu, \sigma)$ y $\alpha = 0.05$,

$$\text{HDI} = (\mu - 1.96\sigma, \mu + 1.96\sigma)$$

- Éste intervalo se conoce comúnmente como el *intervalo de credibilidad de 95 %*.

4 Probabilidad Conjunta y Marginal

Resultados de un referendo en dos regiones

		Región 1	
		Gana G_1	Pierde P_1
Región 2	Gana G_2	A 02	B 01
	Pierde P_2	C 04	D 03

Podemos pensar en términos de eventos

- $P(G_1) = P(A) + P(C) = 06$.
- $P(P_1) = P(B) + P(D) = 04$.
- Etc.

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 01
	Pierde $Y_2 = 0$	(1, 0) 04	(0, 0) 03

O podemos pensar en variables aleatorias

- Y_1 : Resultado en la región 1
- Y_2 : Resultado en la región 2
- Variable vectorial

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix}$$

equivalente a $Y = [Y_1, Y_2]^\top$

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 01
	Pierde $Y_2 = 0$	(1, 0) 04	(0, 0) 03

Introducimos la *pmf conjunta*

$$\begin{aligned}p_Y(y) &= p_{Y_1 Y_2}(y_1, y_2) \\ &= P(\{Y_1 = y_1\} \cup \{Y_2 = y_2\})\end{aligned}$$

- $p_{Y_1 Y_2}(1, 0) = 04$
- $p_{Y_1 Y_2}(0, 0) = 03$
- Etc.

Probabilidad conjunta y marginal

Considérese las dos variables aleatorias

$$X: \Omega \rightarrow C_X, \quad Y: \Omega \rightarrow C_Y$$

- **pmf conjunta**

$$p_{XY}(x, y) = P(\{X = x\} \cup \{Y = y\})$$

Considérese las dos variables aleatorias

$$X: \Omega \rightarrow C_X, \quad Y: \Omega \rightarrow C_Y$$

- **pmf conjunta**

$$p_{XY}(x, y) = P(\{X = x\} \cup \{Y = y\})$$

La pmf conjunta completamente define la distribución de probabilidad de ambas variables aleatorias

Considérese las dos variables aleatorias

$$X: \Omega \rightarrow C_X, \quad Y: \Omega \rightarrow C_Y$$

- **pmf conjunta**

$$p_{XY}(x, y) = P(\{X = x\} \cap \{Y = y\})$$

La pmf conjunta completamente define la distribución de probabilidad de ambas variables aleatorias

- **pmfs marginales**

$$p_X(x) = \sum_{y \in C_Y} p_{XY}(x, y), \quad p_Y(y) = \sum_{x \in C_X} p_{XY}(x, y)$$

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 01
	Pierde $Y_2 = 0$	(1, 0) 04	(0, 0) 03

pmf marginal de Y_1

$$\begin{aligned}
 p_{Y_1}(1) &= \sum_{y_2} p_{Y_1 Y_2}(1, y_2) \\
 &= p_{Y_1 Y_2}(1, 1) + p_{Y_1 Y_2}(1, 0) \\
 &= 02 + 04 = 06
 \end{aligned}$$

$$\begin{aligned}
 p_{Y_1}(0) &= \sum_{y_2} p_{Y_1 Y_2}(0, y_2) \\
 &= p_{Y_1 Y_2}(0, 1) + p_{Y_1 Y_2}(0, 0) \\
 &= 01 + 03 = 04
 \end{aligned}$$

Dos variables aleatorias son independientes si y sólo si

$$p(x, y) = p(x)p(y) \quad \text{para todo } x \in C_X, y \in C_Y$$

i.e., si la pmf conjunta se factoriza en términos de las pmfs marginales

- Independencia implica que observar una variable aleatoria no provee información acerca del valor de la otra variable aleatoria

Resultados de un referendo en dos regiones

		Región 1	
		Gana	Pierde
		$Y_1 = 1$	$Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 005
	Pierde $Y_2 = 0$	(1, 0) 01	(0, 0) 065

- $p_{Y_1}(1) = 0.3$
 - $p_{Y_2}(1) = 0.25$
 - $p_{Y_1 Y_2}(1, 1) = 0.02 \neq 0.3 \times 0.25$
- ... por lo tanto, Y_1 y Y_2 **no** son independientes

Introducimos la *pmf condicional* $p_{X|Y}(x | y)$

- Indica la probabilidad de $X = x$ dado que se ha observado que $Y = y$
- Relacionada con la pmf conjunta y las pmfs marginales a través de la relación

$$p_{XY}(x, y) = p_{X|Y}(x | y)p_Y(y)$$

- Naturalmente,

$$p_{XY}(x, y) = p_{Y|X}(y | x)p_X(x)$$

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 005
	Pierde $Y_2 = 0$	(1, 0) 01	(0, 0) 065

Se observa que el referendo *gana* en la región 2. Cuál es la probabilidad de ganar en la región 1?

$$\begin{aligned} p_{Y_1|Y_2}(1 | 1) &= \frac{p_{Y_1 Y_2}(1, 1)}{p_{Y_2}(1)} \\ &= \frac{02}{025} \approx 08 \end{aligned}$$

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 005
	Pierde $Y_2 = 0$	(1, 0) 01	(0, 0) 065

Se observa que el referendo *gana* en la región 2. Cuál es la probabilidad de ganar en la región 1?

$$\begin{aligned} p_{Y_1|Y_2}(1 | 1) &= \frac{p_{Y_1 Y_2}(1, 1)}{p_{Y_2}(1)} \\ &= \frac{02}{025} \approx 08 \end{aligned}$$

Compárese:

- $p_{Y_1}(1) = 03$
- $p_{Y_1|Y_2}(1 | 1) = 08$

Resultados de un referendo en dos regiones

		Región 1	
		Gana $Y_1 = 1$	Pierde $Y_1 = 0$
Región 2	Gana $Y_2 = 1$	(1, 1) 02	(0, 1) 005
	Pierde $Y_2 = 0$	(1, 0) 01	(0, 0) 065

Se observa que el referendo *gana* en la región 2. Cuál es la probabilidad de ganar en la región 1?

$$\begin{aligned} p_{Y_1|Y_2}(1 | 1) &= \frac{p_{Y_1 Y_2}(1, 1)}{p_{Y_2}(1)} \\ &= \frac{02}{025} \approx 08 \end{aligned}$$

Compárese:

- $p_{Y_1}(1) = 03$
- $p_{Y_1|Y_2}(1 | 1) = 08$

Observar Y_2 provee información acerca de Y_1

Para dos variables aleatorias independientes,

$$p_{XY}(x, y) = p_X(x)p_Y(y)$$

Por lo tanto,

$$p_{X|Y}(x | y) = \frac{p_{XY}(x, y)}{p_Y(y)} = \frac{p_X(x)p_Y(y)}{p_Y(y)} = p_X(x)$$

i.e, la probabilidad de $X = x$ es independiente del valor de Y

Considérese dos variables aleatorias continuas

$$X: \Omega \rightarrow C_X, \quad Y: \Omega \rightarrow C_Y$$

- **pdf conjunta** $p_{XY}(x, y)$
Generaliza el concepto de pmf conjunta a variables continuas
- **pdf marginales**

$$p_X(x) = \int_{C_Y} p_{XY}(x, y) dy, \quad p_Y(y) = \int_{C_X} p_{XY}(x, y) dx$$

Ejemplo: Variable aleatoria normal multivariante (n -variante)

$$Y = [Y_1, Y_2, \dots, Y_n]^\top, \quad Y \sim \mathcal{N}(\mu, C),$$

donde


- $\mu = [\mu_1, \mu_2, \dots, \mu_n]^\top$ es el vector de medias
- C es la matrix $n \times n$ de *covarianza*

En el caso bivalente,


$$C = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

donde ρ denota la correlación entre Y_1 y Y_2

Ejemplo: Variable aleatoria normal bivalente




$\rho = 0.0$



$\rho = 0.6$


Variables aleatorias continuas

Ejemplo: Variable aleatoria normal bivalente con $\rho = 0$



Variables aleatorias continuas

Ejemplo: Variable aleatoria normal bivalente con $\rho = 06$



Lanzar una moneda cargada

- Se lanza una moneda cargada n (e.g., $n = 100$) veces
- Se observa un número y (e.g., $y = 43$) de caras
- Cuál es la probabilidad θ de obtener cara?

Lanzar una moneda cargada

- Se lanza una moneda cargada n (e.g., $n = 100$) veces
- Se observa un número y (e.g., $y = 43$) de caras
- Cuál es la probabilidad θ de obtener cara?

Cómo podemos resolver éste problema?

- *Frecuentista*: Estimador de máxima verosimilitud

$$\hat{\theta} = \frac{y}{n} = \frac{43}{100} = 0.43$$

Lanzar una moneda cargada

- Se lanza una moneda cargada n (e.g., $n = 100$) veces
- Se observa un número y (e.g., $y = 43$) de caras
- Cuál es la probabilidad θ de obtener cara?

Cómo podemos resolver éste problema?

- *Frecuentista*: Estimador de máxima verosimilitud

$$\hat{\theta} = \frac{y}{n} = \frac{43}{100} = 0.43$$

- *Bayesiano*

Lanzar una moneda cargada

Análisis Bayesiano

- 1 Tratamos a y y θ como variables aleatorias Y y Θ
- 2 Observamos Y y buscamos calcular la distribución de P condicional a la observación de Y

$$p_{\Theta|Y}(\theta | y) = \frac{p_{Y\Theta}(y, \theta)}{p_Y(y)} = \frac{p_{Y\Theta}(y, \theta)}{\int p_{Y\Theta}(y, \theta) dy}$$

Análisis Bayesiano

- 1 Tratamos a y y θ como variables aleatorias Y y Θ
- 2 Observamos Y y buscamos calcular la distribución de P condicional a la observación de Y

$$p_{\Theta|Y}(\theta | y) = \frac{p_{Y\Theta}(y, \theta)}{p_Y(y)} = \frac{p_{Y\Theta}(y, \theta)}{\int p_{Y\Theta}(y, \theta) dy}$$

Necesitamos especificar la densidad conjunta $p_{Y\Theta}(y, \theta)$

Lanzar una moneda cargada

Cómo especificar la densidad conjunta $p_{Y\Theta}(y, \theta)$?

- Si se conoce θ , podemos modelar la densidad de Y

$$p_{Y|\Theta}(y | \theta) = \text{Binomial}(y | \theta)$$

En otras palabras, podemos modelar la densidad condicional $p_{Y|\Theta}(y | \theta)$

Cómo especificar la densidad conjunta $p_{Y\Theta}(y, \theta)$?

- Si se conoce θ , podemos modelar la densidad de Y

$$p_{Y|\Theta}(y | \theta) = \text{Binomial}(y | \theta)$$

En otras palabras, podemos modelar la densidad condicional $p_{Y|\Theta}(y | \theta)$

- Dada la definición de probabilidad condicional,

$$p_{Y\Theta}(y, \theta) = p_{Y|\Theta}(y | \theta)p_{\Theta}(\theta)$$

En otras palabras, hace falta especificar $p_{\Theta}(\theta)$

Lanzar una moneda cargada

Cómo especificar $p_{\Theta}(\theta)$?

- Antes de observar Y no sabemos mucho de la distribución de los valores de Θ . Es decir, no sabemos qué valores de Θ son más probables que otros...
- ...pero sabemos que $\Theta \in [0, 1]$

Cómo especificar $p_{\Theta}(\theta)$?

- Antes de observar Y no sabemos mucho de la distribución de los valores de Θ . Es decir, no sabemos qué valores de Θ son más probables que otros...
- ...pero sabemos que $\Theta \in [0, 1]$
- Entonces podemos asumir que $\Theta \sim U(0, 1)$.

Lanzar una moneda cargada

Cómo especificar $p_{\Theta}(\theta)$?

- Antes de observar Y no sabemos mucho de la distribución de los valores de Θ . Es decir, no sabemos qué valores de Θ son más probables que otros...
- ...pero sabemos que $\Theta \in [0, 1]$
- Entonces podemos asumir que $\Theta \sim U(0, 1)$.

Utilizamos el concepto de probabilidad como medida de
(in)certidumbre

- La suposición $\Theta \sim U(0, 1)$ codifica nuestro nivel de certidumbre acerca del valor de Θ

Lanzar una moneda cargada

$$p_{\Theta|Y}(\theta | y) = \frac{P_{Y|\Theta}(y | \theta)p_{\Theta}(\theta)}{\int p_{Y|\Theta}(y | \theta)p_{\Theta}(\theta) d\theta}$$

- Tenemos $p_{Y|\Theta}(y | \theta) = \text{Binomial}(y | \theta)$
- Tenemos $p_{\Theta}(\theta) = U(\theta | 0, 1)$
- Listo! Podemos evaluar la integral del denominador y ya...
- ...pero no vamos a hacer eso

$$p_{\Theta|Y}(\theta | y) = \frac{P_{Y|\Theta}(y | \theta)p_{\Theta}(\theta)}{\int p_{Y|\Theta}(y | \theta)p_{\Theta}(\theta) d\theta}$$

- Calcular la integral en el denominador (*función de partición*) es sencillo cuando son pocos parámetros pero es muy costoso computacionalmente cuando son muchos parámetros
- Utilizaremos una familia de algoritmos, **Monte Carlo de cadenas de Markov (MCMC)** para generar directamente muestras de la distribución $p_{\Theta|Y}(\theta | y)$ sin tener que calcular la integral

Monte Carlo de cadenas de Markov (MCMC)

- Se generan una o varias “cadenas” de números
- En el límite de convergencia, las cadenas corresponden a conjuntos de muestras de la distribución condicional $p_{\Theta|Y}(\theta | y)$
- Es el algoritmo de cálculos Bayesianos más costoso y más general

Ejemplo: Binomial

Revisemos el *Notebook* llamado “*binomial.ipynb*”.

- Acceda a GoogleColaboratory.
- Cargue el archivo `binomial.ipynb`.
- Siga paso a paso la guía.

5 Modelamiento probabilístico

- **Objetivo:** Modelar datos
- Si tenemos observaciones y de un observable Y y un modelo de las observaciones parametrizado por Θ , podemos calcular la distribución de los parámetros dadas las observaciones usando

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)} = \frac{p(y | \theta)p(\theta)}{\int p(y | \theta)p(\theta) d\theta}$$

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)} = \frac{p(y | \theta)p(\theta)}{\int p(y | \theta)p(\theta) d\theta}$$

- $p(y | \theta)$: **Verosimilitud**

El valor de la pdf de las observaciones dado el valor específico $\Theta = \theta$ de los parámetros. La verosimilitud indica qué tan posible es observar las (uh) observaciones dado θ

- $p(\theta)$: **(Distribución) Anterior**

Codifica la información disponible o suposiciones acerca de la distribución de probabilidad de Θ , i.e, indica qué valores de Θ son más o menos probables de acuerdo a la información *a priori*

$$p(\theta | y) = \frac{p(y | \theta)p(\theta)}{p(y)} = \frac{p(y | \theta)p(\theta)}{\int p(y | \theta)p(\theta) d\theta}$$

- $p(\theta | y)$: **(Distribución) Posterior**

pdf de Θ dadas las observaciones, i.e., indica qué valores de Θ son más o menos probables de acuerdo a las observaciones y la información *a priori*

- $p(y) = \int p(y | \theta)p(\theta) d\theta$: **Verosimilitud marginal**

Indica qué valores del observable Y son más o menos posibles dada la información *a priori* acerca de los parámetros del modelo

- Para calcular la distribución posterior sólo hace especificar las verosimilitud $p(y \mid \theta)$ y la distribución anterior, i.e, la distribución conjunta

$$p(y, \theta) = p(y \mid \theta)p(\theta)$$

- Ésta distribución conjunta se conoce como el *modelo probabilístico*

- Queremos analizar la dependencia de un observable Y en una variable explicatoria x utilizando un modelo parametrizado por Θ
- Dadas las observaciones (X, y) , podemos calcular la distribución de los parámetros:

$$p(\theta \mid y, X) = \frac{p(y \mid X, \theta)p(\theta)}{p(y \mid X)} = \frac{p(y \mid X, \theta)p(\theta)}{\int p(y \mid X, \theta)p(\theta) d\theta}$$

donde

- $p(y \mid X, \theta)$: Verosimilitud
- $p(\theta)$: Anterior
- $p(\theta \mid y, X)$: Posterior

Ejemplo: Reactor

Revisemos el *Notebook* llamado “*reactor.ipynb*”.

- Ingrese a *Google Colaboratory*.
- Siga paso a paso la guía.

Regresión lineal ordinaria

- Tenemos un observable Y , que se asume continua y k variables explicatorias $x = (x_1, x_2, \dots, x_k)$
- Un número n de observaciones de la forma

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_i \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1k} \\ x_{21} & x_{22} & \dots & x_{2k} \\ \vdots & & & \vdots \\ x_{i1} & x_{i2} & \dots & x_{ik} \\ \vdots & & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix}$$

- Modelo lineal para la esperanza de las observaciones


$$\mathbb{E}(y_i \mid X, \theta) = \alpha + x_{i1}\beta_1 + x_{i2}\beta_2 + \dots x_{ik}\beta_k$$

$$\mathbb{E}(y \mid X, \theta) = \alpha + X\beta$$

Verosimilitud normal

- Para modelar las observaciones, asumimos que cada observación es independiente, y modelada como una variable aleatoria normal con la esperanza dada por el modelo lineal y una cierta varianza

$$p(y_i | X, \theta) = \mathcal{N}(y_i | \alpha + X_i \cdot \beta, \sigma), \quad \theta = \{\alpha, \beta, \sigma\}$$

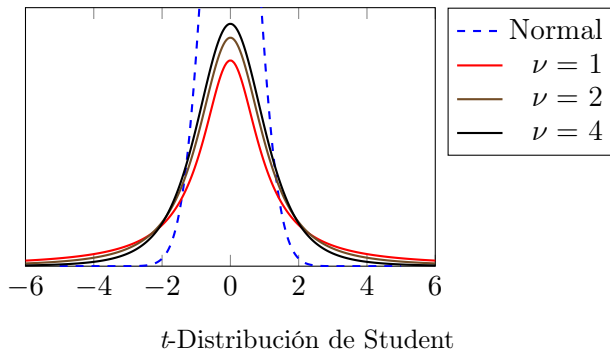


- La distribución conjunta de las observaciones es

$$p(y | X, \theta) = \prod_{i=1}^n p(y_i | X, \theta) = \mathcal{N}(y | \alpha + X\beta, \sigma^2 I)$$

- La distribución normal tiene colas “cortas”. Por lo tanto, observaciones lejos del predictor $\alpha + X\beta$ para cierto valor de θ se consideran muy poco probables
- Éstas observaciones “arrastran” el estimador hacia ellas
- Para robustecer la inferencia contra valores extremos es necesario utilizar una verosimilitud con colas más largas

Robustez contra valores extremos



- Cómo decidir el valor de ν ?
- Modelamiento jerárquico.

- Las distribuciones anteriores de los parámetros, θ , se eligen usualmente como distribuciones parametrizadas de la forma $p(\theta | \nu)$ con sus propios parámetros ν , o *hiperparámetros*
- Podemos asignar *distribuciones hiperanteriores* $p(\nu)$ a éstos hiperparámetros

$$p(\theta, \nu | y, X) = \frac{p(y | X, \theta)p(\theta | \nu)p(\nu)}{\int p(y | X, \theta)p(\theta | \nu)p(\nu) d\theta d\nu}$$

Ejemplo:Robustez

Revisemos el *Notebook* de Jupyter llamado “*robust.ipynb*”.

- Ingrese a *Google Colaboratory*.
- Siga paso a paso la guía.